



Hands-On

Hands-On ini digunakan pada kegiatan Microcredential Associate Data Scientist 2021

Tugas Mandiri Pertemuan 15

Pertemuan 15 (limabelas) pada Microcredential Associate Data Scientist 2021 menyampaikan materi mengenai Membangun Model (Clustering). silakan Anda kerjakan Latihan 1 s/d 10. Output yang anda lihat merupakan panduan yang dapat Anda ikuti dalam penulisan code :)

Customer Segmentation

Dalam Kasus ini, kita akan melakukan pengelompokan data tanpa pengawasan /unsupervised clustering pada catatan pelanggan dari database perusahaan bahan makanan. Segmentasi pelanggan/Customer segmentation adalah praktik memisahkan pelanggan ke dalam kelompok-kelompok yang mencerminkan kesamaan di antara pelanggan di setiap cluster. Kita akan membagi pelanggan menjadi beberapa segmen untuk mengoptimalkan signifikansi setiap pelanggan bagi bisnis. Untuk memodifikasi produk sesuai dengan kebutuhan dan perilaku pelanggan yang berbeda. Ini juga membantu bisnis untuk memenuhi kekhawatiran berbagai jenis pelanggan.

TABLE OF CONTENTS

1. IMPORTING LIBRARIES
2. LOADING DATA
3. DATA CLEANING
4. DATA PREPROCESSING
5. DIMENSIONALITY REDUCTION
6. CLUSTERING
7. EVALUATING MODELS

8. PROFILING

9. CONCLUSION

10. END

IMPORTING LIBRARIES

Latihan (1)

```
# Import library numpy untuk operasi fungsi aritmatika  
import numpy as np
```

```
# import library pandas untuk operasi dataframe  
import pandas as pd
```

```
# Import library matplotlib dan seaborn untuk visualisasi  
import matplotlib.pyplot as plt  
import seaborn as sns  
#.....  
#.....
```

```
# Import library Axes3D untuk vizualisasi 3 Dimensi  
from mpl_toolkits.mplot3d import Axes3D
```

```
# import library datetime untuk operasi yang berhubungan dengan waktu.  
import datetime
```

```
# import library Label encoder untuk mengubah setiap nilai dalam kolom  
menjadi angka yang berurutan / numeric  
from sklearn import preprocessing
```

```
# import library StandardScaler untuk menskalakan nilai kolom jika  
terdapat perbedaan skala, StandardScaler berfungsi menghilangkan mean  
(terpusat pada 0) dan menskalakan ke variansi (deviasi standar = 1),  
dengan asumsi data terdistribusi normal (gauss) untuk semua fitur  
from sklearn.preprocessing import StandardScaler
```

```
# import library PCA adalah prosedur statistik yang mengekstrak fitur-  
fitur terpenting dari suatu dataset  
from sklearn.decomposition import PCA
```

```
# import library KElbowVisualizer untuk mengimplementasikan metode  
"elbow/siku" untuk data scientist memilih jumlah cluster yang optimal  
dengan menyesuaikan model dengan rentang nilai untuk K  
from yellowbrick.cluster import KElbowVisualizer
```

```

# import library KMeans metode adalah teknik unsupervised machine
learning yang digunakan untuk mengidentifikasi kelompok objek data
dalam kumpulan data
from sklearn.cluster import KMeans

#.....

# import library AgglomerativeClustering untuk melakukan pengelompokan
data menggunakan bottom-up manner
from sklearn.cluster import AgglomerativeClustering

# import library metrics untuk mengimplementasikan fungsi yang menilai
kesalahan prediksi untuk tujuan tertentu
from sklearn.metrics import accuracy_score

# me-non aktifkan peringatan pada python
import warnings
warnings.filterwarnings("ignore")

# mendefinisikan nilai acak
from numpy.random import rand

values = rand(42)

```

LOADING DATA

Latihan (2)

```

#Load the dataset dan tampilkan data nya
data = 'marketing.csv'
df = pd.read_csv(data)
df.head(5)

```

	ID	Year_Birth	Education	Marital_Status	Income	Kidhome
Teenhome \						
0	5524	1957	Graduation	Single	58138.0	0
0						
1	2174	1954	Graduation	Single	46344.0	1
1						
2	4141	1965	Graduation	Together	71613.0	0
0						
3	6182	1984	Graduation	Together	26646.0	1

0	4	5324	1981	PhD	Married	58293.0	1
0							
		Dt_Customer	Recency	MntWines	...	NumWebVisitsMonth	AcceptedCmp3
\	0	04-09-2012	58	635	...	7	0
	1	08-03-2014	38	11	...	5	0
	2	21-08-2013	26	426	...	4	0
	3	10-02-2014	26	11	...	6	0
	4	19-01-2014	94	173	...	5	0
		AcceptedCmp4	AcceptedCmp5	AcceptedCmp1	AcceptedCmp2	Complain	\
0		0	0	0	0	0	
1		0	0	0	0	0	
2		0	0	0	0	0	
3		0	0	0	0	0	
4		0	0	0	0	0	
		Z_CostContact	Z_Revenue	Response			
0		3	11	1			
1		3	11	0			
2		3	11	0			
3		3	11	0			
4		3	11	0			

[5 rows x 29 columns]

Untuk informasi lebih lanjut tentang atribut data [disini](#).

DATA CLEANING

Di bagian ini

- Data Cleaning
- Feature Engineering

Untuk mendapatkan pemahaman penuh tentang langkah-langkah apa yang harus kita ambil untuk membersihkan dataset. Mari kita lihat informasi dalam data.

Latihan (3)

Melihat Informasi lebih detail mengenai struktur DataFrame dapat dilihat menggunakan fungsi info()

`df.info()`

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2240 entries, 0 to 2239
Data columns (total 29 columns):
 #   Column                Non-Null Count  Dtype
---  -
 0   ID                    2240 non-null   int64
 1   Year_Birth            2240 non-null   int64
 2   Education             2240 non-null   object
 3   Marital_Status       2240 non-null   object
 4   Income                2216 non-null   float64
 5   Kidhome               2240 non-null   int64
 6   Teenhome              2240 non-null   int64
 7   Dt_Customer          2240 non-null   object
 8   Recency               2240 non-null   int64
 9   MntWines              2240 non-null   int64
10  MntFruits             2240 non-null   int64
11  MntMeatProducts       2240 non-null   int64
12  MntFishProducts       2240 non-null   int64
13  MntSweetProducts      2240 non-null   int64
14  MntGoldProds          2240 non-null   int64
15  NumDealsPurchases     2240 non-null   int64
16  NumWebPurchases       2240 non-null   int64
17  NumCatalogPurchases  2240 non-null   int64
18  NumStorePurchases     2240 non-null   int64
19  NumWebVisitsMonth     2240 non-null   int64
20  AcceptedCmp3          2240 non-null   int64
21  AcceptedCmp4          2240 non-null   int64
22  AcceptedCmp5          2240 non-null   int64
23  AcceptedCmp1          2240 non-null   int64
24  AcceptedCmp2          2240 non-null   int64
25  Complain              2240 non-null   int64
26  Z_CostContact         2240 non-null   int64
27  Z_Revenue             2240 non-null   int64
28  Response              2240 non-null   int64
dtypes: float64(1), int64(25), object(3)
memory usage: 507.6+ KB
```

Dari output di atas, kita dapat menyimpulkan dan mencatat bahwa:

- Ada nilai yang hilang/missing value dalam kolom income
- Dt_Customer yang menunjukkan tanggal pelanggan bergabung dengan database tidak diuraikan sebagai DateTime
- Ada beberapa fitur kategoris dalam dataframe; karena ada beberapa fitur bertipe object. Jadi kita perlu mengkodekannya ke dalam bentuk numerik nanti.

Pertama-tama, untuk nilai yang hilang, kita hanya akan menghapus baris yang memiliki nilai pendapatan yang hilang.

menghapus missing values

`df.dropna()`

	ID	Year_Birth	Education	Marital_Status	Income	
Kidhome \	5524	1957	Graduation	Single	58138.0	0
0						
1	2174	1954	Graduation	Single	46344.0	1
2	4141	1965	Graduation	Together	71613.0	0
3	6182	1984	Graduation	Together	26646.0	1
4	5324	1981	PhD	Married	58293.0	1
...
2235	10870	1967	Graduation	Married	61223.0	0
2236	4001	1946	PhD	Together	64014.0	2
2237	7270	1981	Graduation	Divorced	56981.0	0
2238	8235	1956	Master	Together	69245.0	0
2239	9405	1954	PhD	Married	52869.0	1

	Teenhome	Dt_Customer	Recency	MntWines	...	NumWebVisitsMonth
\						
0	0	04-09-2012	58	635	...	7
1	1	08-03-2014	38	11	...	5
2	0	21-08-2013	26	426	...	4
3	0	10-02-2014	26	11	...	6
4	0	19-01-2014	94	173	...	5
...
2235	1	13-06-2013	46	709	...	5

2236	1	10-06-2014	56	406	...	7
2237	0	25-01-2014	91	908	...	6
2238	1	24-01-2014	8	428	...	3
2239	1	15-10-2012	40	84	...	7

	AcceptedCmp3	AcceptedCmp4	AcceptedCmp5	AcceptedCmp1
AcceptedCmp2 \				
0	0	0	0	0
0				
1	0	0	0	0
0				
2	0	0	0	0
0				
3	0	0	0	0
0				
4	0	0	0	0
0				
...
...				
2235	0	0	0	0
0				
2236	0	0	0	1
0				
2237	0	1	0	0
0				
2238	0	0	0	0
0				
2239	0	0	0	0
0				

	Complain	Z_CostContact	Z_Revenue	Response
0	0	3	11	1
1	0	3	11	0
2	0	3	11	0
3	0	3	11	0
4	0	3	11	0
...
2235	0	3	11	0
2236	0	3	11	0
2237	0	3	11	0
2238	0	3	11	0
2239	0	3	11	1

[2216 rows x 29 columns]

Pada langkah selanjutnya, kita akan membuat fitur dari "**Dt_Customer**" yang menunjukkan jumlah hari pelanggan terdaftar di database perusahaan. Namun, untuk membuatnya tetap sederhana, kita mengambil nilai ini relatif terhadap pelanggan terbaru dalam catatan.

Jadi untuk mendapatkan nilai, kita harus memeriksa tanggal rekaman terbaru dan terlama.

```
data['Dt_Customer'] = pd.to_datetime(data['Dt_Customer'])
dates = []
for i in data['Dt_Customer']:
    i = i.date()
    dates.append(i)

# Tanggal pelanggan terbaru dan terlama yang tercatat
print('Tanggal pendaftaran pelanggan terbaru dalam catatan:')
print('Tanggal pendaftaran pelanggan terbaru dalam catatan: ')
```

```
-----
-----
TypeError                                Traceback (most recent call
last)
<ipython-input-12-cff49585df7a> in <module>
----> 1 data['Dt_Customer'] = pd.to_datetime(data['Dt_Customer'])
      2 dates = []
      3 for i in data['Dt_Customer']:
      4     i = i.date()
      5     dates.append(i)
```

TypeError: string indices must be integers

Membuat fitur ("**Customer_For**") dari jumlah hari pelanggan mulai berbelanja di toko relatif terhadap tanggal terakhir yang tercatat

```
# Membuat fitur "Customer_For"
days = []
d1 = max(dates) # membawanya menjadi pelanggan terbaru
for i in dates:
    delta = d1 - i
    days.append(delta)
data["Customer_For"] = days
data["Customer_For"] = pd.to_numeric(data["Customer_For"],
errors="coerce")
```

```
-----
-----
NameError                                Traceback (most recent call
last)
<ipython-input-13-1b95a1d24920> in <module>
      1 # Membuat fitur "Customer_For"
      2 days = []
----> 3 d1 = max(dates) # membawanya menjadi pelanggan terbaru
      4 for i in dates:
```



```
5      delta = d1 - i
```

NameError: name 'dates' is not defined

Sekarang kita akan mengeksplorasi nilai unik dalam fitur kategoris untuk mendapatkan gambaran yang jelas tentang data.

```
print("Total kategori dalam fitur Marital_Status:\n\n",
data["Marital_Status"].value_counts(), "\n")
print("Total kategori dalam fitur Education:\n\n",
data["Education"].value_counts())
```

```
-----
-----
TypeError                                Traceback (most recent call
last)
<ipython-input-14-c6016dbd97ea> in <module>
----> 1 print("Total kategori dalam fitur Marital_Status:\n\n",
data["Marital_Status"].value_counts(), "\n")
      2 print("Total kategori dalam fitur Education:\n\n",
data["Education"].value_counts())
```

TypeError: string indices must be integers

Latihan (4)

Pada step berikutnya, kita akan melakukan langkah-langkah berikut untuk merekayasa beberapa fitur baru:

- Ekstrak "**Age**" dari pelanggan dengan "**Year_Birth**" yang menunjukkan tahun lahir orang yang bersangkutan.
- Buat fitur lain "**Spent**" yang menunjukkan jumlah total yang dibelanjakan oleh pelanggan dalam berbagai kategori selama rentang waktu dua tahun.
- Buat fitur lain "**Living_With**" dari "**Marital_Status**" untuk mengekstrak situasi kehidupan pasangan.
- Buat fitur "**Children**" untuk menunjukkan jumlah anak dalam rumah tangga, anak-anak dan remaja.
- Untuk mendapatkan kejelasan lebih lanjut tentang rumah tangga, Membuat fitur yang menunjukkan "**Family_Size**"
- Buat fitur "**Is_Parent**" untuk menunjukkan status orang tua
- Terakhir, kita akan membuat tiga kategori di "**Education**" dengan menyederhanakan penghitungan nilainya.
- Menjatuhkan beberapa fitur yang berlebihan / redundant features

```
#Feature Engineering
```

```
# Usia pelanggan hari ini  
data =
```

```
# Total pengeluaran untuk berbagai macam item  
.....
```

```
# situasi kehidupan dari status pernikahan "Alone"  
.....
```

```
# Fitur yang menunjukkan jumlah anak yang tinggal di rumah tangga  
.....
```

```
# Fitur untuk total anggota dalam rumah tangga  
.....
```

```
# Fitur yang berkaitan dengan orang tua  
.....
```

```
# Segmentasi tingkat pendidikan dalam tiga kelompok  
.....
```

```
# Untuk kejelasan produk  
.....
```

```
# Drop / Menjatuhkan beberapa fitur yang berlebihan / redundant  
features  
.....  
.....
```

Sekarang kita memiliki beberapa fitur baru, mari kita lihat statistik data.

```
# melihat statistik data untuk data numeric  
data.describe()
```

	Income	Kidhome	Teenhome	Recency
Wines \				
count	2216.000000	2216.000000	2216.000000	2216.000000
mean	52247.251354	0.441787	0.505415	49.012635
std	305.091606	0.536896	0.544181	28.948352
min	1730.000000	0.000000	0.000000	0.000000
25%	35303.000000	0.000000	0.000000	24.000000
50%	51381.500000	0.000000	0.000000	49.000000
75%	71381.500000	0.000000	0.000000	74.000000
max	174.500000	0.000000	0.000000	74.000000

75%	68522.000000	1.000000	1.000000	74.000000
505.000000				
max	666666.000000	2.000000	2.000000	99.000000
1493.000000				

	Fruits	Meat	Fish	Sweets	Gold
... \					
count	2216.000000	2216.000000	2216.000000	2216.000000	2216.000000
...					
mean	26.356047	166.995939	37.637635	27.028881	43.965253
...					
std	39.793917	224.283273	54.752082	41.072046	51.815414
...					
min	0.000000	0.000000	0.000000	0.000000	0.000000
...					
25%	2.000000	16.000000	3.000000	1.000000	9.000000
...					
50%	8.000000	68.000000	12.000000	8.000000	24.500000
...					
75%	33.000000	232.250000	50.000000	33.000000	56.000000
...					
max	199.000000	1725.000000	259.000000	262.000000	321.000000
...					

	AcceptedCmp1	AcceptedCmp2	Complain	Response
Customer_For \				
count	2216.000000	2216.000000	2216.000000	2216.000000
2.216000e+03				
mean	0.064079	0.013538	0.009477	0.150271
4.423735e+16				
std	0.244950	0.115588	0.096907	0.357417
2.008532e+16				
min	0.000000	0.000000	0.000000	0.000000
0.000000e+00				
25%	0.000000	0.000000	0.000000	0.000000
2.937600e+16				
50%	0.000000	0.000000	0.000000	0.000000
4.432320e+16				
75%	0.000000	0.000000	0.000000	0.000000
5.927040e+16				
max	1.000000	1.000000	1.000000	1.000000
9.184320e+16				

	Age	Spent	Children	Family_Size	Is_Parent
count	2216.000000	2216.000000	2216.000000	2216.000000	2216.000000
mean	52.179603	607.075361	0.947202	2.592509	0.714350
std	11.985554	602.900476	0.749062	0.905722	0.451825

min	25.000000	5.000000	0.000000	1.000000	0.000000
25%	44.000000	69.000000	0.000000	2.000000	0.000000
50%	51.000000	396.500000	1.000000	3.000000	1.000000
75%	62.000000	1048.000000	1.000000	3.000000	1.000000
max	128.000000	2525.000000	3.000000	5.000000	1.000000

[8 rows x 28 columns]

Latihan (5)

Statistik di atas menunjukkan beberapa perbedaan dalam rata - rata Pendapatan dan income, dan maksimal pendapatan Usia/Age.

Perhatikan bahwa usia maksimal adalah 128 tahun, Karena kita menghitung usia yang akan menjadi hari ini (yaitu 2021) dan datanya sudah tua.

Kita harus melihat pada pandangan yang lebih luas dari data.

Kita akan memplot beberapa fitur yang dipilih.

```
#To plot some selected features
#Setting up colors preferences
```

```
.....
.....
.....
```

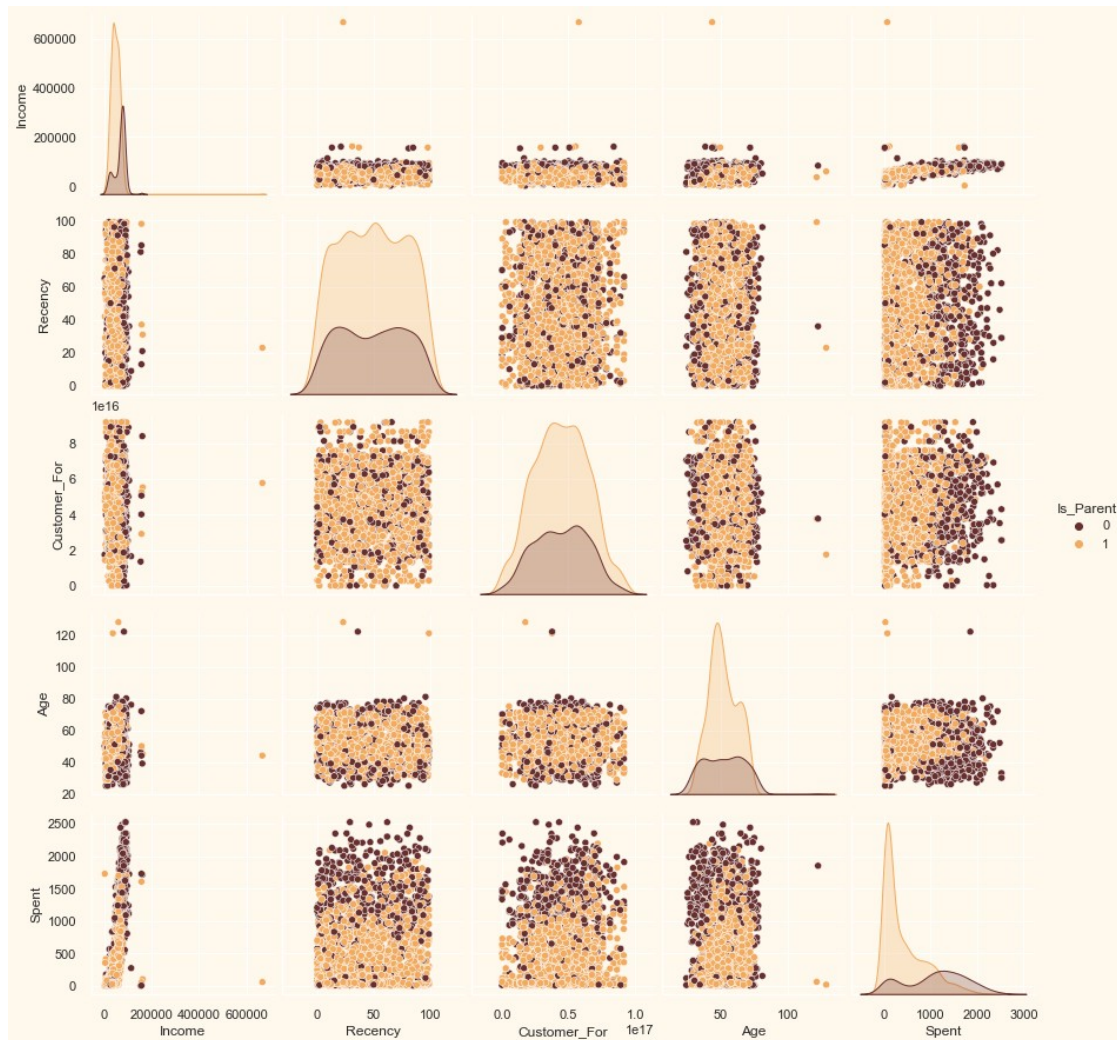
```
#Plotting fitur
```

```
.....
.....
.....
.....
```

```
plt.show()
```

Plot Relatif Dari Beberapa Fitur Terpilih: Subset Data

<Figure size 576x396 with 0 Axes>



Jelas, ada beberapa outlier dalam fitur Pendapatan dan Usia.

Kita akan menghapus outlier dalam data.

```
# Drop outlier dengan menetapkan batas pada Usia dan pendapatan.
data = data[(data["Age"]<90)]
data = data[(data["Income"]<600000)]
print("Jumlah total data setelah menghapus outlier adalah:",
len(data))
```


Jumlah total data setelah menghapus outlier adalah: 2212

Selanjutnya, mari kita lihat korelasi di antara fitur-fiturnya.

(Tidak termasuk atribut kategoris pada saat ini)

```
#correlation matrix
.....
.....
.....
```

<AxesSubplot:>



Datanya cukup bersih dan fitur-fitur baru telah disertakan. Kita akan melanjutkan ke langkah berikutnya. Yaitu mengolah data terlebih dahulu.

DATA PREPROCESSING

Pada bagian ini, kita akan melakukan preprocessing data untuk melakukan operasi clustering.

Langkah-langkah berikut diterapkan untuk memproses data sebelumnya:

- Label encoding/Label pengkodean fitur kategoris
- Menskalakan fitur menggunakan scaler standar
- Membuat subset dataframe untuk pengurangan dimensi / dimensionality reduction

Latihan (6)

```
# Get List dari variabel categorical
```

```
.....
.....
```

```
print("Variabel kategori dalam dataset:", object_cols)
```

```
Variabel kategori dalam dataset: ['Education', 'Living_With']
```

```
# Label Encoding (dtypes: objek)
```

```
LE=LabelEncoder()
```

```
for i in object_cols:
```

```
    data[i]=data[[i]].apply(LE.fit_transform)
```

```
print("Semua fitur sekarang numerik")
```

```
Semua fitur sekarang numerik
```

```
# Membuat salinan data
```

```
.....
```

```
# membuat subset dataframe dengan menghapus fitur pada penawaran yang diterima (features on deals accepted) dan promosi (promotions)
```

```
.....
.....
```

```
#Scaling
```

```
.....
.....
.....
.....
```

```
Semua fitur sekarang sudah diskalakan
```

```
# Data yang diskalakan untuk digunakan untuk mengurangi dimensi/reducing the dimensionality
```

```
.....
.....
```

```
Dataframe yang akan digunakan untuk pemodelan lebih lanjut:
```

	Education	Income	Kidhome	Teenhome	Recency	Wines
Fruits \						
0	-0.893586	0.287105	-0.822754	-0.929699	0.310353	0.977660
1.552041						
1	-0.893586	-0.260882	1.040021	0.908097	-0.380813	-0.872618

```

0.637461
2 -0.893586  0.913196 -0.822754 -0.929699 -0.795514  0.357935
0.570540
3 -0.893586 -1.176114  1.040021 -0.929699 -0.795514 -0.872618 -
0.561961
4  0.571657  0.294307  1.040021 -0.929699  1.554453 -0.392257
0.419540

```

```

      Meat      Fish      Sweets  ...  NumCatalogPurchases
NumStorePurchases \
0  1.690293  2.453472  1.483713  ...           2.503607      -
0.555814
1 -0.718230 -0.651004 -0.634019  ...          -0.571340      -
1.171160
2 -0.178542  1.339513 -0.147184  ...          -0.229679
1.290224
3 -0.655787 -0.504911 -0.585335  ...          -0.913000      -
0.555814
4 -0.218684  0.152508 -0.001133  ...           0.111982
0.059532

```

```

      NumWebVisitsMonth  Customer_For      Age      Spent  Living_With
Children \
0      0.692181      1.973583  1.018352  1.676245  -1.349603 -
1.264598
1     -0.132545     -1.665144  1.274785 -0.963297  -1.349603
1.404572
2     -0.544908     -0.172664  0.334530  0.280110   0.740959 -
1.264598
3      0.279818     -1.923210 -1.289547 -0.920135   0.740959
0.069987
4     -0.132545     -0.822130 -1.033114 -0.307562   0.740959
0.069987

```

```

      Family_Size  Is_Parent
0     -1.758359  -1.581139
1      0.449070   0.632456
2     -0.654644  -1.581139
3      0.449070   0.632456
4      0.449070   0.632456

```

[5 rows x 23 columns]

DIMENSIONALITY REDUCTION

Dalam masalah ini, ada banyak faktor yang menjadi dasar klasifikasi akhir akan dilakukan. Faktor-faktor ini pada dasarnya adalah atribut atau fitur. Semakin tinggi jumlah fitur,

semakin sulit untuk bekerja dengannya. Banyak dari fitur ini berkorelasi, dan karenanya berlebihan/redundant. Inilah sebabnya mengapa kita akan melakukan pengurangan dimensi pada fitur yang dipilih sebelum menempatkannya melalui pengklasifikasi. *Pengurangan dimensi/Dimensionality reduction adalah proses mengurangi jumlah variabel acak yang dipertimbangkan, dengan memperoleh satu set variabel utama.*

Principal component analysis (PCA) adalah teknik untuk mengurangi dimensi kumpulan data tersebut, meningkatkan kemampuan interpretasi tetapi pada saat yang sama meminimalkan kehilangan informasi.

Langkah - langkah pada bagian ini:

- Pengurangan dimensi dengan PCA
- Plotting the reduced dataframe

Dimensionality reduction with PCA

Untuk kasus ini, kita akan mengurangi dimensi menjadi 3.

Latihan (7)

Memulai PCA untuk mengurangi dimensi alias fitur menjadi 3

```
.....  
.....  
.....  
.....
```

	count	mean	std	min	25%	50%
75% \						
col1	2212.0	5.882375e-17	2.878377	-5.969394	-2.538494	-0.780421
2.383290						
col2	2212.0	2.549698e-17	1.706839	-4.312196	-1.328316	-0.158123
1.242289						
col3	2212.0	6.098196e-18	1.221956	-3.530416	-0.829067	-0.022692
0.799895						

	max
col1	7.444305
col2	6.142721
col3	6.611222


Proyeksi 3D Data Dalam Dimensi yang Dikurangi/Reduced Dimension

```
.....  
.....  
.....
```

plotting

```
fig = plt.figure(figsize=(10,8))  
ax = fig.add_subplot(111, projection="3d")  
ax.scatter(x,y,z, c="maroon", marker="o" )
```

```
ax.set_title("Proyeksi 3D Data Dalam Dimensi yang Dikurangi/Reduced  
Dimension")  
plt.show()
```



CLUSTERING

Sekarang kita telah mengurangi atribut menjadi tiga dimensi, kita akan melakukan pengelompokan melalui pengelompokan Agglomerative. Pengelompokan aglomeratif adalah metode pengelompokan hierarkis. Ini melibatkan penggabungan contoh sampai jumlah cluster yang diinginkan tercapai.

Langkah-langkah yang dilakukan dalam Clustering

- Metode Elbow untuk menentukan jumlah cluster yang akan dibentuk
- Clustering melalui Agglomerative Clustering
- Memeriksa cluster yang terbentuk melalui scatter plot


Latihan (8)

Quick examination of elbow method to find numbers of clusters to make.

```
print('Metode Elbow untuk menentukan jumlah cluster yang akan
dibentuk:')
```

```
.....
.....
.....
```

Metode Elbow untuk menentukan jumlah cluster yang akan dibentuk:



```
<AxesSubplot:title={'center': 'Distortion Score Elbow for KMeans
Clustering'}, xlabel='k', ylabel='distortion score'>
```

Sel di atas menunjukkan bahwa empat akan menjadi jumlah cluster yang optimal untuk data ini.

Selanjutnya, kita akan fit Model Agglomerative Clustering untuk mendapatkan cluster akhir.

```
# Memulai model Agglomerative Clustering
```

```
.....
```

```
# fit model and predict clusters
```

```
.....  
.....
```

```
# Menambahkan fitur Cluster ke dataframe asli.
```

```
.....
```

Untuk memeriksa cluster yang terbentuk mari kita lihat distribusi 3-D dari cluster.

```
#Plotting clusters
```


```
fig = plt.figure(figsize=(10,8))
```

```
ax = plt.subplot(111, projection='3d', label="bla")
```

```
ax.scatter(x, y, z, s=40, c=PCA_ds["Clusters"], marker='o', cmap =  
cmap )
```

```
ax.set_title("Plot Clusters")
```

```
plt.show()
```



EVALUATING MODELS

Karena ini adalah unsupervised clustering. Kita tidak memiliki fitur yang ditandai untuk mengevaluasi atau menilai model kita. Tujuan dari bagian ini adalah untuk mempelajari pola-pola dalam kluster yang terbentuk dan menentukan sifat dari pola kluster tersebut.


Untuk itu, kita akan melihat data berdasarkan cluster melalui analisis data eksplorasi dan menarik kesimpulan.

Pertama, mari kita lihat distribusi grup dari clustering

Latihan (9)

#Plotting countplot dari clusters

```
.....  
.....  
.....  
.....
```




Cluster tampaknya cukup terdistribusi.

```
pl = sns.scatterplot(data = data,x=data["Spent"],  
y=data["Income"],hue=data["Clusters"], palette= pal)
```

```

plt.set_title("Profil Cluster Berdasarkan Income Dan Spending")
plt.legend()
plt.show()

```



Income vs spending plot menunjukkan pola cluster

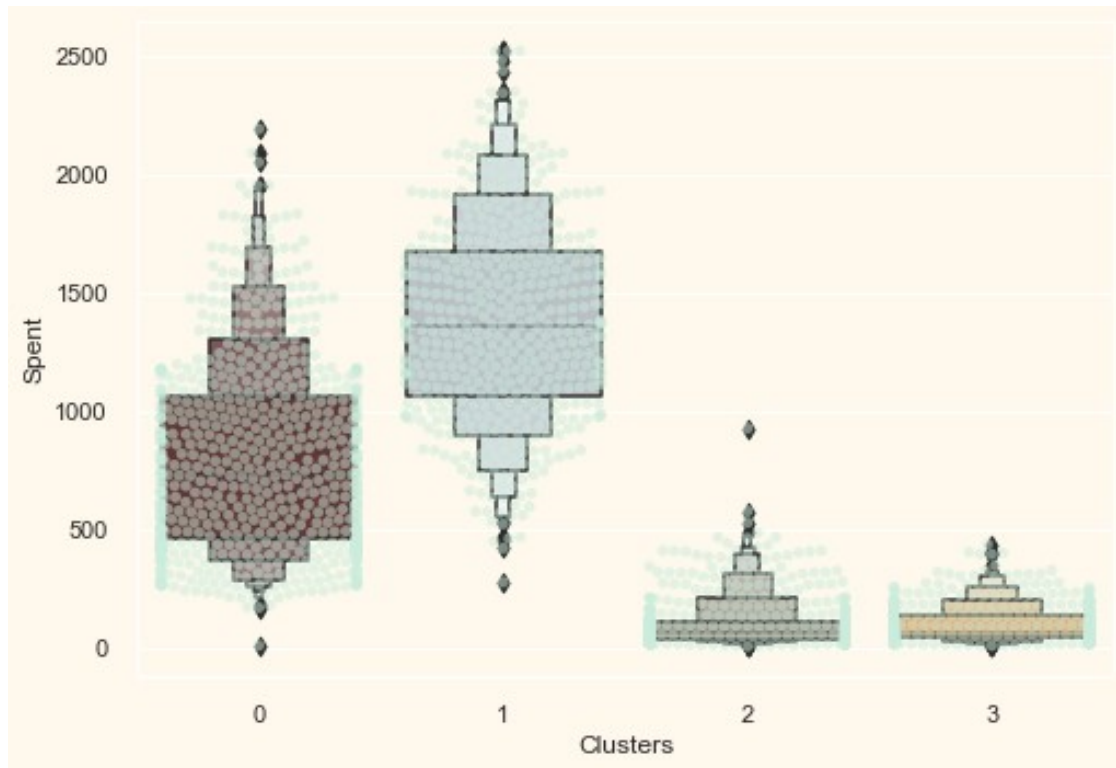
- group 0: high spending & average income
- group 1: high spending & high income
- group 2: low spending & low income
- group 3: high spending & low income

Selanjutnya, kita akan melihat distribusi klaster yang terperinci sesuai dengan berbagai produk dalam data. Yaitu: Wines, Fruits, Meat, Fish, Sweets dan Gold

```

plt.figure()
pl=sns.swarmplot(x=data["Clusters"], y=data["Spent"], color=
"#CBEDDD", alpha=0.5 )
pl=sns.boxenplot(x=data["Clusters"], y=data["Spent"], palette=pal)
plt.show()

```




Dari plot di atas, dapat dilihat dengan jelas bahwa cluster 1 adalah kumpulan pelanggan terbesar kita diikuti oleh cluster 0. Kita dapat mengeksplorasi apa yang dibelanjakan setiap cluster untuk strategi pemasaran yang ditargetkan.

Selanjutnya mari kita jelajahi bagaimana kinerja kampanye kita di masa lalu.

```
# Membuat fitur untuk mendapatkan sejumlah promosi yang
diterima/accepted promotions
data["Total_Promos"] = data["AcceptedCmp1"]+ data["AcceptedCmp2"]+
data["AcceptedCmp3"]+ data["AcceptedCmp4"]+ data["AcceptedCmp5"]

# plotting Jumlah dari total kampanye yang diterima.
plt.figure()
pl = sns.countplot(x=data["Total_Promos"],hue=data["Clusters"],
palette= pal)
pl.set_title("Jumlah dari Promotion Accepted")
pl.set_xlabel("Angka/number dari Total Accepted Promotions")
plt.show()
```




Sejauh ini belum ada tanggapan yang luar biasa terhadap kampanye tersebut. Sangat sedikit peserta secara keseluruhan. Selain itu, tidak ada satu bagian yang mengambil semua 5 dari mereka. Mungkin diperlukan kampanye yang lebih tepat sasaran dan terencana dengan baik untuk meningkatkan penjualan.

#Plotting jumlah transaksi yang dibeli / deals purchased

.....

plt.show()




Tidak seperti kampanye, penawaran yang ditawarkan berhasil dengan baik. Ini memiliki hasil terbaik dengan cluster 0 dan cluster 3. Namun, pelanggan bintang kita cluster 1 tidak terlalu tertarik dengan kesepakatan. Sepertinya tidak ada yang menarik cluster 2 secara berlebihan

untuk detail lebih lanjut tentang gaya pembelian/purchasing style


.....

```
for i in Places:
    plt.figure()
    sns.jointplot(x=data[i],y = data["Spent"],hue=data["Clusters"],
    palette= pal)
    plt.show()
```


<Figure size 576x396 with 0 Axes>



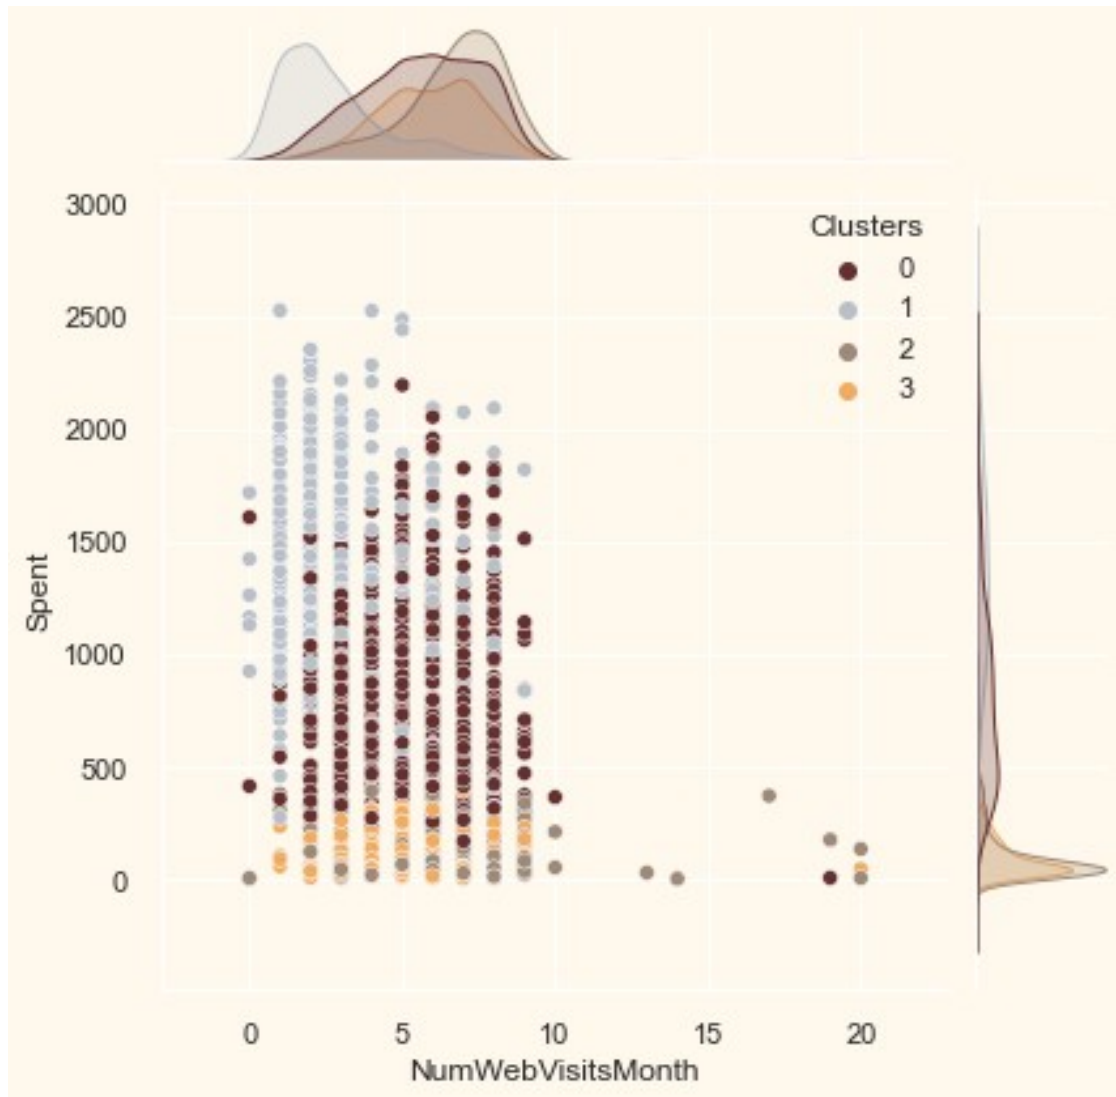
<Figure size 576x396 with 0 Axes>



<Figure size 576x396 with 0 Axes>



<Figure size 576x396 with 0 Axes>



PROFILING

Sekarang kita telah membentuk klaster dan melihat kebiasaan pembelian mereka. Mari kita lihat siapa saja yang ada di cluster ini. Untuk itu, kita akan membuat profil klaster-klaster yang terbentuk dan sampai pada kesimpulan tentang siapa pelanggan utama kita dan siapa yang membutuhkan perhatian lebih dari tim pemasaran toko ritel.

Untuk memutuskan bahwa kita akan merencanakan beberapa fitur yang menunjukkan ciri-ciri pribadi pelanggan dalam terang cluster mereka masuk Atas dasar hasil, kita akan sampai pada kesimpulan.

Latihan (10)


```
Personal = [ "Kidhome", "Teenhome", "Customer_For", "Age", "Children",  
"Family_Size", "Is_Parent", "Education", "Living_With"]
```

```
for i in Personal:  
    plt.figure()  
    sns.jointplot(x=data[i], y=data["Spent"], hue =data["Clusters"],  
kind="kde", palette=pal)  
    plt.show()
```


#Berikan Penjelasan dari coding ini!

.....
.....
.....
.....

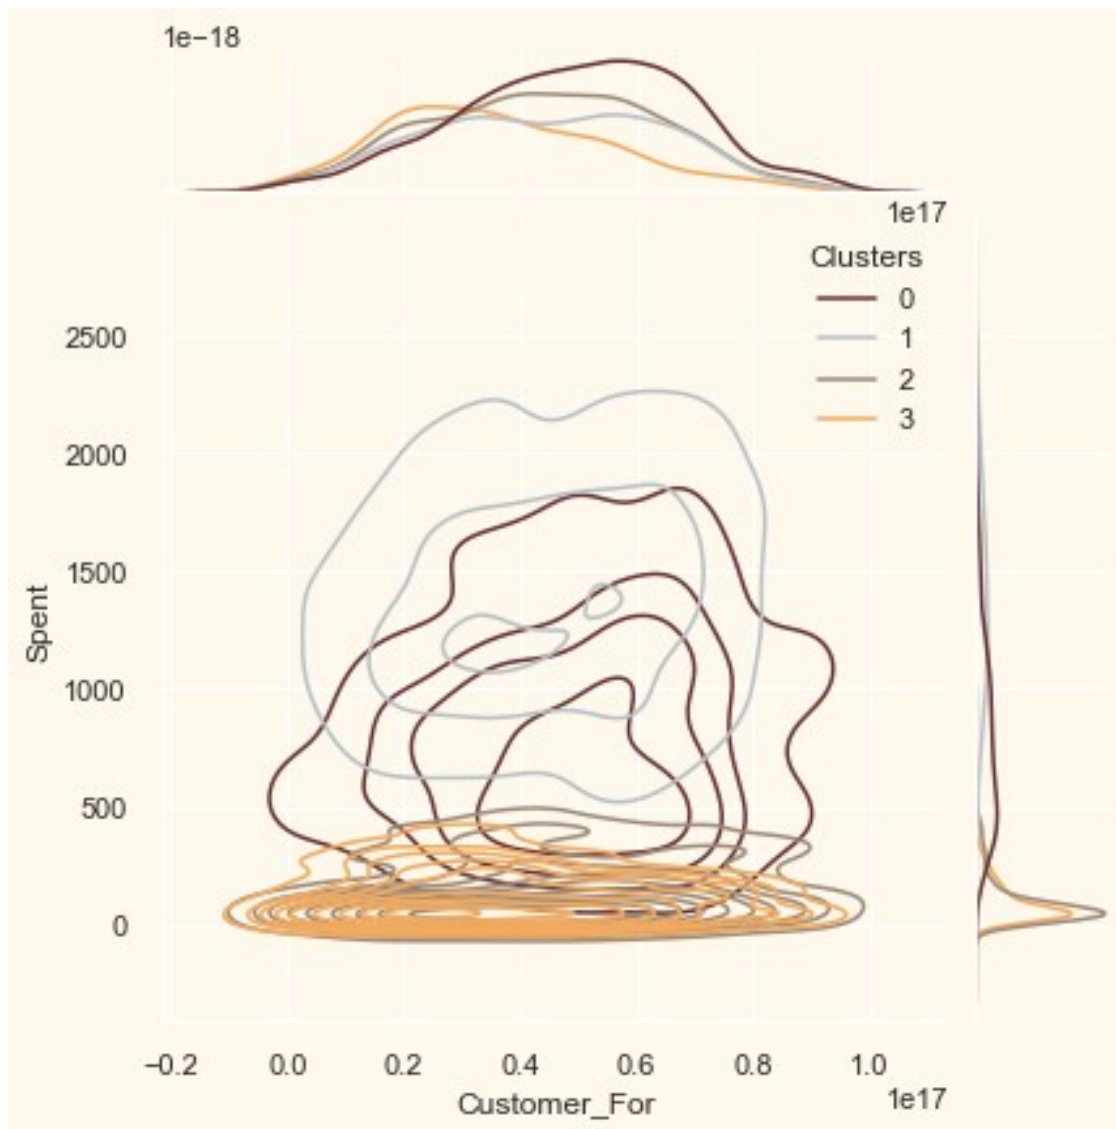
<Figure size 576x396 with 0 Axes>




<Figure size 576x396 with 0 Axes>



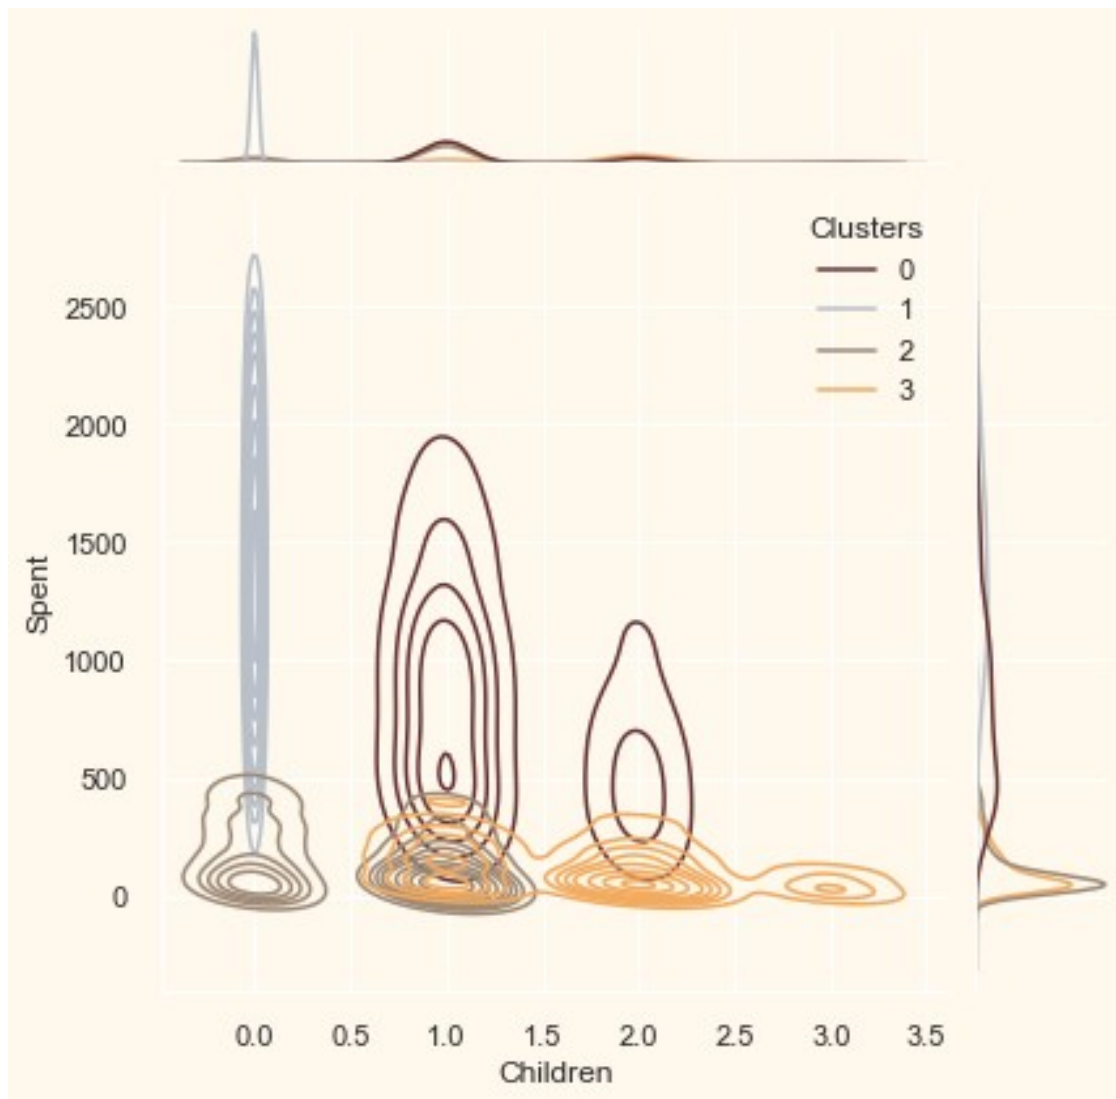
<Figure size 576x396 with 0 Axes>



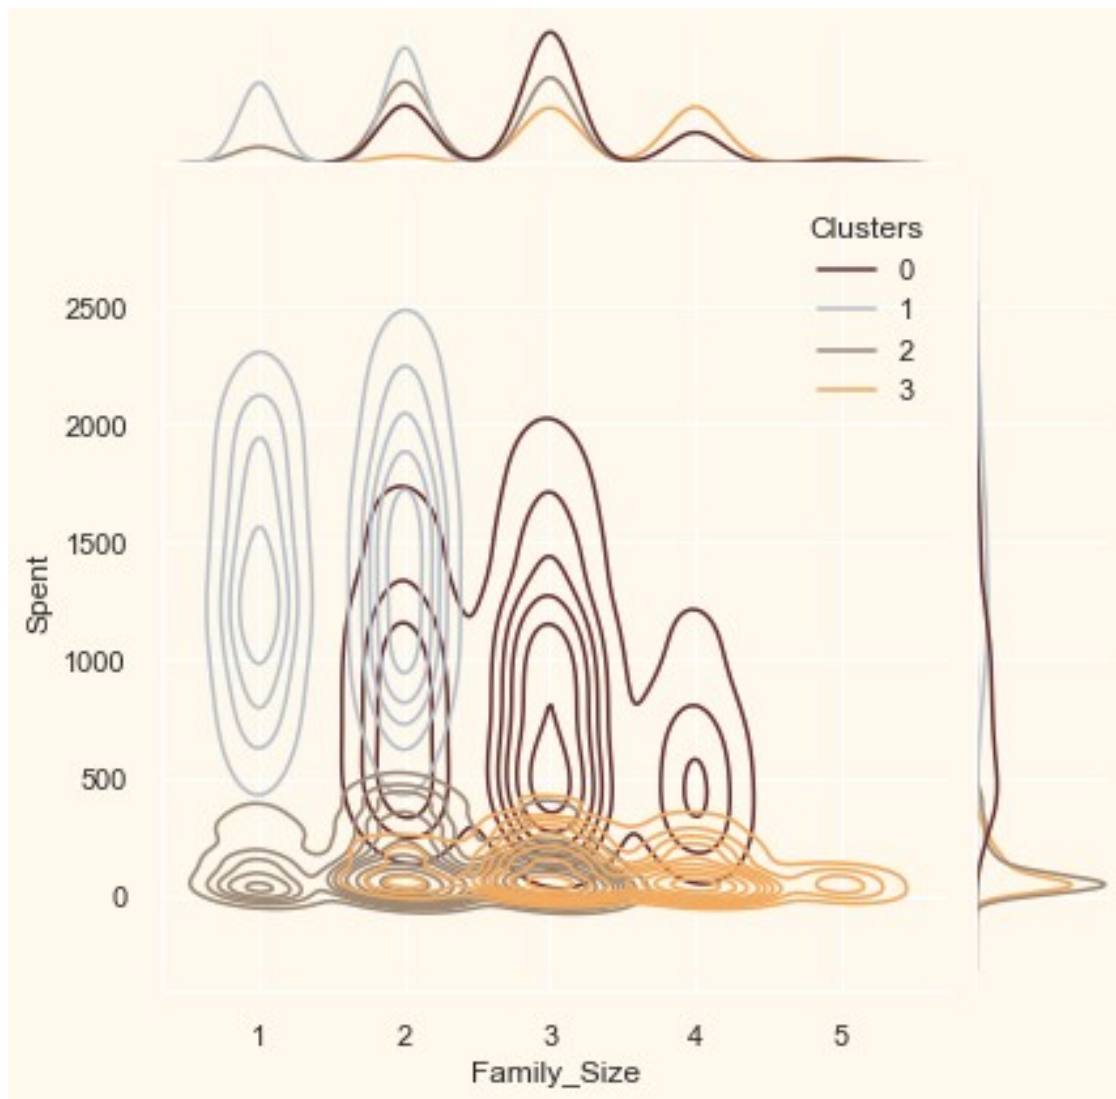
<Figure size 576x396 with 0 Axes>



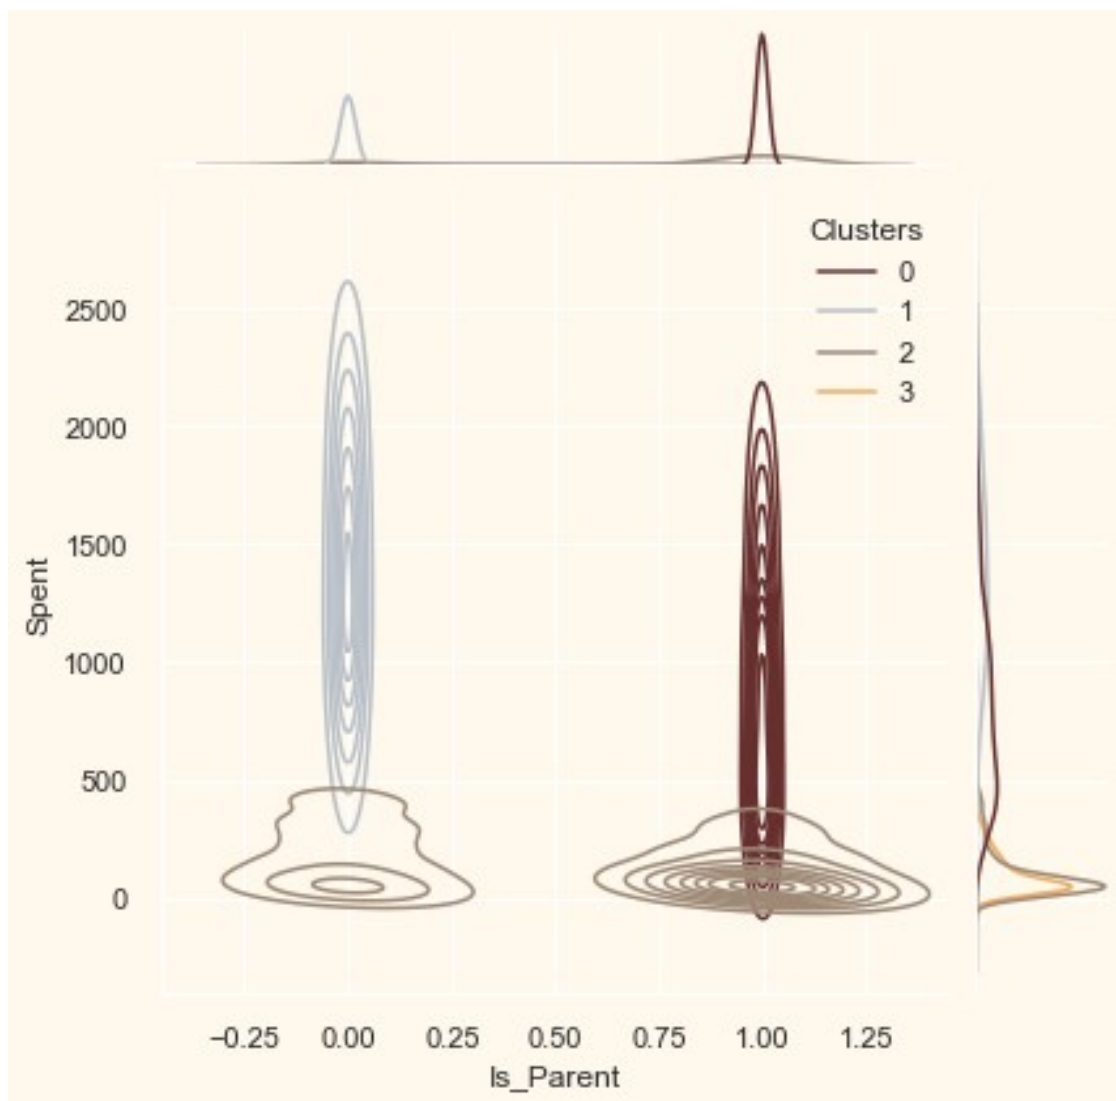
<Figure size 576x396 with 0 Axes>




<Figure size 576x396 with 0 Axes>




<Figure size 576x396 with 0 Axes>



<Figure size 576x396 with 0 Axes>



<Figure size 576x396 with 0 Axes>



Hal-hal yang perlu diperhatikan:

Informasi berikut dapat disimpulkan tentang pelanggan di cluster yang berbeda.

CONCLUSION

Dalam kasus ini, kita melakukan unsupervised clustering. Kita memang menggunakan pengurangan dimensi/dimensionality reduction diikuti oleh agglomerative clustering. Kita datang dengan 4 cluster dan selanjutnya menggunakannya dalam membuat profil pelanggan dalam cluster sesuai dengan struktur keluarga dan pendapatan/pengeluaran mereka (income/spending).

Ini dapat digunakan dalam merencanakan strategi pemasaran yang lebih baik!

Terimakasih Semoga dapat menambah akan pemahaman kalian!

END